Final Source of Truth

Prompt Evaluation & Optimization System

编写者：Zane Jenkins | 项目：Leo × Zane AIGC Pipeline | 最后更新：2026-03-14
涵盖：生产架构 · 三份核心 Prompt 模板 · 实验数据 · 技术选型研究 · 闭环路线图

Prompt Evaluation & Optimization System

Final Source of Truth

> 编写者：Zane | 最后更新：2026-03-14 本文档为项目唯一权威参考，整合了 Leo 的研究文档、生产 Prompt 模板、实验数据及阶段性结论。

一、项目背景与动机

为什么做这个

在 AIGC 视频生产流水线中，Prompt 是连接输入与输出的核心环节。好的 Prompt → 稳定、自然的视频；差的 Prompt → 抖动、动作循环、背景扭曲。全自动化流水线中，这个问题尤其关键。

当前面临的四个核心问题：

1. **没有标准** — "好视频"的定义因人而异，缺乏可量化的评判标准
2. **没有数据** — 修改 Prompt 后，效果是变好还是变差？只能靠人工抽查几条，凭直觉判断
3. **没有积累** — 今天的好 Prompt 不一定适用明天不同的场景，经验无法沉淀
4. **没有闭环** — 没有数据就无法系统性改进，只能反复试错

核心理念（来自 Anthropic Evaluation Harness）

评测一个系统，评的不是单个模型，而是整个 pipeline（结构化输入 + 模型 + 评分器）的协同效果。

实际意义：即使 Seedance（生成模型）固定不变，通过优化 Prompt 结构和 QC 标准，也能持续提升系统表现。评测系统本身是改进工具，不只是检验工具。

策略

1. **先建基础设施**：结构化 Prompt + 自动 QC + 数据积累
2. **再用数据驱动优化**：DSPy 自动优化、Reward Model 训练
3. **核心原则**：边生产边评测（build while producing）——评测是持续基础设施，不是一次性检验。流水线运行 → 数据积累 → 数量足够后 → 分析和训练

二、生产流水线架构

主流程

```
原始图片
  ↓
CLIP + YOLO + Aesthetic Scoring（~2.5秒/张）
  ↓
图片分析 JSON（场景、主体、瑕疵、人脸、文字…）
  ↓
Gemini + gemini_image_analysis.txt → Seedream 4.5
（修复瑕疵 / 16:9→9:16 纵向 / 色彩校正 / 人脸处理）
  ↓
增强后的图片
  ↓
Gemini + gemini_cinematography_prompt.txt
（结构化 JSON → 30-45 词 Seedance Prompt）
  ↓
Seedance 1.5 Pro（图生视频，8秒，1080p，9:16）
  ↓
视频
  ↓
QC 旁路（异步，不阻塞生产）
  ↓
Lark Base 写入（全量记录）
```

当前处理规模： 45个文件夹，1004张图片，约2.5秒/张

QC 旁路逻辑

```
视频 → Gemini QC 评分 → 是否通过?
                          ├── 通过 → 保留
```

```
                    └── 不通过 → 删除 + 恢复原图
                → Lark Base（全量结果入库）
```

三、三份核心 Prompt 模板（生产级）

3.1 gemini_image_analysis.txt — 图片分析模板

作用： 接收原始图片，输出结构化 JSON，驱动 Seedream 增强

输出字段：

字段	说明
scene	场景描述（一句话）
main_subject	核心主体（必须保留）
subject_position	主体位置（center / left third 等）
current_aspect / target_aspect	当前/目标宽高比（目标始终为 9:16）
extend_top/bottom/left/right	各边延伸纹理描述（视觉描述，非分类名）
preserve	3-5 个必须保留的元素
lighting_current / lighting_fix	当前光照 / 需要调整的内容
color_style	色彩风格（保持自然，不做 HDR）
defects	需要修复的瑕疵列表
faces	人脸处理：quality=natural → keep；morphed/distorted/blurry → remove person（整人 inpaint 掉）
text	文字处理：signage → preserve；watermark → remove
remove	需要移除/inpaint 的元素

关键规则： 增强后的图片必须看起来像一张曝光良好的照片，不能像 AI 生成图或 HDR 效果。

3.2 gemini_enhancement_prompt_9x16.txt — Seedream 增强模板

作用： 将图片分析 JSON 转成 Seedream 自然语言增强指令

6步流程：

1. **Reframing** — 宽高比转换（16:9→9:16），用纹理描述填充延伸区域
2. **Removals** — 瑕疵/变形人脸 → 用周围纹理填充（fill with surrounding texture）
3. **Lighting & Color** — 仅做细微调整（KEEP IT SUBTLE）
4. （保留步骤）
5. **Preservation** — 明确哪些元素不能改变
6. **Negative Constraints** — 固定结尾："No new text or signs. Enhance subtly, natural photograph look. No fog, haze, lens flares, new people. Extended areas text-free."

10条规则（重点）： - 只用自然语言，不输出 JSON - 直接指令式表达（"Extend the top with..." 而非 "The top should be extended..."） - 纹理描述词（"white plaster ceiling" 不是 "ceiling"） - 始终以 "9:16 vertical format" 开头 - 始终以 "No new text or signs" 结尾 - 每个任务单独一段 - Subtle is better — 目标是自然照片，不是 AI 艺术风

3.3 gemini_cinematography_prompt.txt — 视频 Prompt 生成模板

作用： 接收场景分析 JSON，输出 30-45 词的 Seedance 视频生成 Prompt

输入字段： scene_description, main_subject, foreground, background, camera_move, camera_direction, shot_size, lighting, subtle_motion, stable_element, sky_instruction

8段式 Prompt 结构：

段	内容
#0	Shot Size（close-up / medium / wide）
#1	Scene Context（一句话场景描述）
#2	Camera Movement（使用官方词汇）
#3	What's Revealed（前景/背景关系）
#4	Lighting（融入自然光照描述）
#5	Subtle Motion（仅一个动态元素）
#6	Stability Anchor（固定元素描述）
#7	Sky/Time Realism（室外场景必加）

Seedance 官方确认可用的镜头词汇： push / pull / pan left・right / move left・right / orbit / follow / rise / lower / zoom

---

四、prompt_evaluator Python 模块

模块结构

```
prompt_evaluator/
├── models.py               # Pydantic 数据模型（全量）
├── reward_calculator.py    # 多维度 Reward 计算
├── prompt_analyzer.py      # Prompt 特征提取 + 相关性分析
├── optimizer.py            # OPRO 优化器（已废弃，TextGrad 替代中）
├── dspy_optimizer.py       # DSPy 优化器（新，已接通 Gemini 实测）
├── calibration.py          # QC 校准（Accuracy/Precision/Recall/F1）
├── pipeline.py             # EvalPipeline 主编排器
├── clients/
│   ├── kie_client.py       # Kie.ai API 封装（图片+视频生成）
│   └── gemini_client.py    # Gemini QC + LLM 客户端
└── tests/                  # 142 个单元测试，全部通过
```

核心类

RewardCalculator — 多维度打分，公式：

```
reward = 50 × pass_flag
       + 20 × (aesthetic_score / 10)
       + 15 × (motion_score / 10)
       + 15 × (adherence_score / 10)
       − minor_issues_count × 2
```

GeminiVideoQC — 视频上传到 Gemini File API → 多模态评测 - Auto-Fail 规则（任一触发即 FAIL）： 人脸变形（五官错位）/ 手指错误（6根/融合）/ 循环 artifact / 穿透问题 / 结构性塌陷 / 严重物体形变 - Minor Issues（累计 ≥2 则 FAIL）： 轻微闪烁 / 颜色不一致 / 边缘细节丢失 / 纹理颤动 - 四维打分（1-10）： aesthetic / motion / prompt_adherence / scroll_stop

KieClient — Kie.ai 封装 - 图片生成：Seedream 4.5 - 视频生成：Seedance 1.5 Pro（默认 1080p / 9:16 / 8 秒 / generate_audio=false） - 内置 Budget Tracker + 指数退避轮询

DSPy Optimizer（新） — 3个模块，均已用真实 Gemini API 测试通过： 1. 生成模块：场景 JSON → 30-48 词 Seedance Prompt 2. Critique 模块：分析 Prompt 失败原因（已正确识别吊灯形变问题） 3. Template 改进模块：基于失败案例自动重写 System Prompt

---

五、System Prompt 演进

版本	结构	平均 Reward	关键变化
hotel_v1	5段式：[镜头]+[场景]+[运动]+[动态]+[稳定锚点]	~71	基线。"Single continuous shot" 开头，含负面约束
hotel_v2_diverse	同 v1，增加镜头多样性	~71	几乎无提升，验证换镜头类型本身没用
hotel_v3	主体优先结构，无负面约束，丰富描述	~82	基于官方指南彻底重写，去掉稳定锚点，加程度副词

v3 对比 v1（12个样本，6个场景）：

场景	v1 Reward	v3 Reward	Delta
pool	45.2	58.4	+13.2
room	94.0	94.0	0
lobby	92.0	69.6	**−22.4**
spa	69.6	90.0	+20.4
restaurant	57.2	92.0	**+34.8**
beach	69.6	86.0	+16.4
平均	**71.3**	**81.7**	**+10.4**

v3 在 4/6 场景胜出，Pass Rate 从 2/6 → 4/6。lobby 回退原因：v3 描述了更多复杂细节（吊灯水晶、倒影等），这类复杂场景反而更容易触发 object_morphing。

六、实验数据总结

API 消耗（截至 2026-03-12）

- Kie.ai：**$20.31**（约 20 次图片生成 + 39 次视频生成）
- Gemini：约 70 次调用（AI Studio 免费额度内，约 $0）

三轮实验结果

轮次	样本数	场景数	平均 Reward	结论
Round 1（v1 baseline）	19	10	70.8	建立基线
Round 2（OPRO 改进）	16	6	62.9	OPRO 反而变差 −7.9
Round 3（v3 vs v1）	12	6	v1=71.3 / v3=81.7	v3 +10.4，正向改进

高频失败原因（所有轮次汇总）

失败类型	出现次数	场景关联
object_morphing	12	大堂（吊灯）、海滩（植物）、餐厅（建筑结构）
action_loop	7	泳池（水面）、水疗（蒸汽）
structural_collapse	5	餐厅、大堂
sky_anomaly	3	所有室外场景

场景难度分级（基于实验数据）

难度	场景	典型 Reward
☒低风险	泳池（简单）、客房（单主体）、外观（静态）	88–94
⚠ 中等	水疗、餐厅（无复杂玻璃反射）	70–85
☒高风险	大堂（吊灯/倒影）、海滩（多动态元素）、浴室（反射）	42–65

七、技术研究：优化方法对比

方法	来源	评价
OPRO	DeepMind, ICLR 2024	将 (prompt, score) 对排序后让 LLM 猜规律。理论直觉，实践有限。我们测试：改了 Prompt 结构反而变差 −7.9
DSPy ⊠	Stanford, 2024-2025	把 Prompt 工程变成"编程"。模块化、可测试、可追踪。MIPROv2 Bayesian 优化比 OPRO 随机搜索效率高。**主选**
TextGrad	Nature, 2024	用 LLM 文字反馈做"梯度"：输出差 → 分析原因 → "反向传播"改 Prompt。方向性强但每轮成本高（3次 LLM 调用）。**备选**
VPO	ICCV 2025	唯一专为视频生成 Prompt 优化设计的方法，核心是收集人类偏好数据训练优化器。**最相关学术研究**

我们测的结论： OPRO 在 "约束词优化" 方向完全走不通（模型忽略负面约束）。DSPy 的 Critique 模块已验证能正确识别失败原因，Template 改进模块也实测通过。下一步：把 generate → score → critique → improve → loop 全链路跑通。

八、技术研究：视频评分方法对比

方法	评价
当前：Gemini QC	自定义 Prompt + Gemini 2.5 Pro 多模态评测。优点：快速、灵活、API 可用。局限：打分标准手写未经 benchmark 校准，跨轮一致性未验证
VideoScore / VideoScore2	TIGER-AI-Lab, EMNLP 2024。专为 AI 视频质量评测训练，5维度与人工判断相关性 77%。HF Space 可用（无需 GPU），VideoScore2（2025）带 CoT 解释。**下一步集成验证**
VBench 2.0	CVPR 2025 标准 benchmark。Human Fidelity / Controllability / Creativity / Physics / Aesthetics 5大维度。适合作为长期对齐标准

九、关键发现（Seedance Prompt 实战规律）

⊠有效： - 程度副词强烈影响输出："slowly", "gently", "gradually"（酒店内容必用） - 每个镜头只用一个动词（多动词 = 几何畸变） - 丰富视觉描述（材质、颜色、光质）显著提升质量 - 风格锚定词有效："cinematic", "editorial", "film grain"

⌧**无效：** - 负面 Prompt 完全不生效（官方确认，所有版本） - 稳定锚点（"stays still", "remains fixed"）被模型忽略 - 器械名称（gimbal, steadicam）在 1.5 Pro 上效果不稳定

⚠ **未验证：** - 正面约束（"Maintain face consistency"）— 2.0 有效，1.5 Pro 未测 - 品质后缀（"4K Ultra HD"）— 可能有效，待 A/B 测试

十、闭环设计：长期路线图

完整闭环

```
生成 Seedance → QC 自动评测 → 数据积累（Lark Base）
      ↑                                    ↓
 更好的视频 ← RLHF/DPO ← Reward Model 训练
```

三个具体方向

方向	内容	时间线
方向1：QC 数据训练 Reward Model	参考 VideoScore 架构 + VBench-2.0 维度，训练酒店场景专用评分模型	中期（数据量依赖）
方向2：Reward 信号优化生成模型	参考 T2V-Turbo-v2，RLHF/DPO 让模型学会"生成高分视频"	长期（需计算资源）
方向3：Fine-tune Prompt Generator	参考 VPO，用 QC 高分视频对应 Prompt 微调生成模块	短期（最快见效）

验证案例：T2V-Turbo-v2

T2V-Turbo-v2（2024）VBench 85.13，学术方法超越 Gen-3/Kling 工业产品。

关键启示： Reward 信号设计 > 原始训练数据量。10× 数据可能只提升 10%，设计良好的 Reward 信号可以提升 50%。

十一、当前进度与下一步

已完成

组件	状态
prompt_evaluator 完整模块	☒142 测试通过，pip installable
三份生产 Prompt 模板	☒完整原文存入 prompts/
KieClient（图片+视频生成）	☒真实 API 验证，1080p 默认
GeminiVideoQC（自动评测）	☒Gemini 2.5 Pro，多模态
System Prompt v3	☒基于官方指南重写，+10.4 avg reward
DSPy Optimizer（3个模块）	☒实测通过 Gemini 调用
35个视频样本 + 数据	☒eval_results/ 存档
两份 TikTok 研究文档（中文）	☒Creator Rewards + 去重机制

立即要做

1. **DSPy 完整优化循环** — 把 generate → score → critique → improve → repeat 跑通，这是当前最大 Gap
2. **QC 一致性验证** — 同一视频跑 3 次取中位数，确认评分稳定
3. **VideoScore2 HF Space 测试** — 验证专业视频评分器能否替代/补充 Gemini QC

API 约束

- Kie.ai key ☒（已存 .credentials/）
- Gemini key ☒（已存 .credentials/）
- generate_audio 始终 false
- 默认：1080p / 9:16 / 8秒
- Seedance 2.0 API 尚未开放（BytePlus 版权争议延期）

附录：项目文件索引

文件	位置	说明
gemini_image_analysis.txt	prompts/	图片分析 Prompt 完整原文
gemini_cinematography_prompt.txt	prompts/	视频 Prompt 生成模板（含5个完整示例）
gemini_enhancement_prompt_9x16.txt	prompts/	Seedream 增强 Prompt（含4个示例）
integration_architecture.md	prompts/	Pipeline 接口定义 + 数据格式
hotel_v1/v2/v3.txt	system_prompts/	System Prompt 各版本
seedance_vocabulary_research.md	research/	Seedance Prompt 词汇实战研究
v3_comparison_20260313_002051.json	eval_results/	v3 vs v1 完整对比数据（12 samples）
PROJECT.md	根目录	技术细节扩展版（英文，460行）